

# LMGTFY - WEB SCRAPING OP BASIS VAN STREEPJESCODE

MARC BOES - DIWUG - 16 FEBRUARI 2021

# KORTE INTRODUCTIE

### ZAKELIJK CIRKELTJE

- OOIT BEGONNEN ALS CITIZEN DEVELOPER AVANT LA LETTRE (MET KLEITABLET, EXCEL 3.0, PAPYRUS, ACCESS 1.1 EN WORD 2.0)
- EIND 20<sup>E</sup> EEUW MS OFFICE AFDELING GESTART BIJ BANK: DESKTOP SERVICES
- MID JAREN NUL EN TIEN MET SHAREPOINT AAN DE SLAG BIJ JSR, WORTELL, MOTION10
- LAATSTE JAREN M365 BIJ EEN ANDERE
  BANK ALS VP DESKTOP SERVICES

### PRIVÉ

- WOONACHTIG IN ROTTERDAM MET VRIENDIN EN KAT
- GROTE KAT OP EERSTE SLIDE
  GEADOPTEERD BIJ STICHTING LEEUW
- HOBBY'S: M365 EN WHISKY VERZAMELEN
- SOCIAL MEDIA: ZO WEINIG MOGELIJK

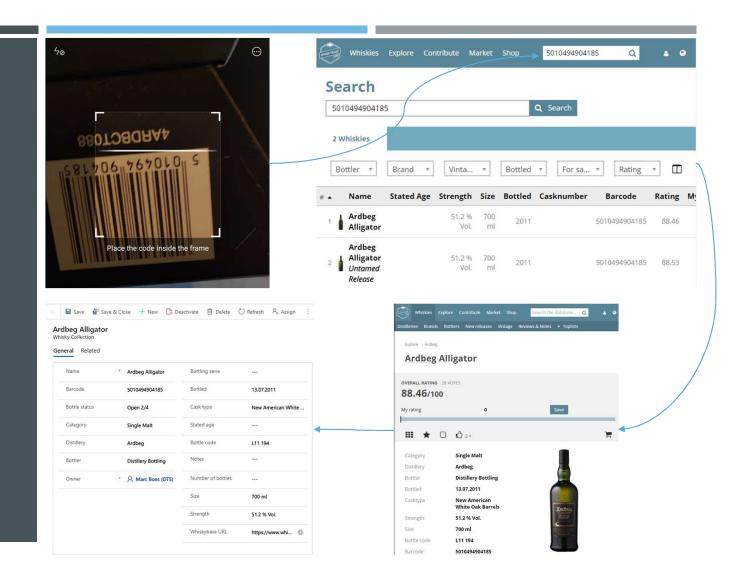
# **OVERZICHT VAN DE PRESENTATIE**

- De aanleiding:
  - Een vrij uitgebreide whiskyverzameling,
  - een M365 Business Standard abonnement,
  - een Azure Pay-As-You-Go Dev/Test abonnement,
  - een prachtige whiskygegevensbron Whiskybase stelt geen data feeds beschikbaar.
- Het doel van de oplossing en het onderwerp van deze presentatie:
  - een zwaluwstaartje tussen de barcode scanner in Power Apps en pagina's van Whiskybase.
- De agenda:
  - De uitdaging, oftewel de handmatige acties die geautomatiseerd gaan worden.
  - De puzzelstukjes, oftewel de componentjes en de links hoe je dit inregelt.
  - Nog even concreet, oftewel de specifieke details van deze oplossing: 30" demo, 5' Function App, 2' AAD protection, 7' connector, z' Power Automate
  - Afsluiting.
- De presentatie met de links en de zelf gebrouwen code is als PDF hier te downloaden

# **DE UITDAGING**

Mobile App met een knop die

- Barcode scant,
- de code opzoekt op Whiskybase,
- de gevonden pagina uitleest,
- de details in het invulscherm plaatst.



## **DE PUZZELSTUKJES**

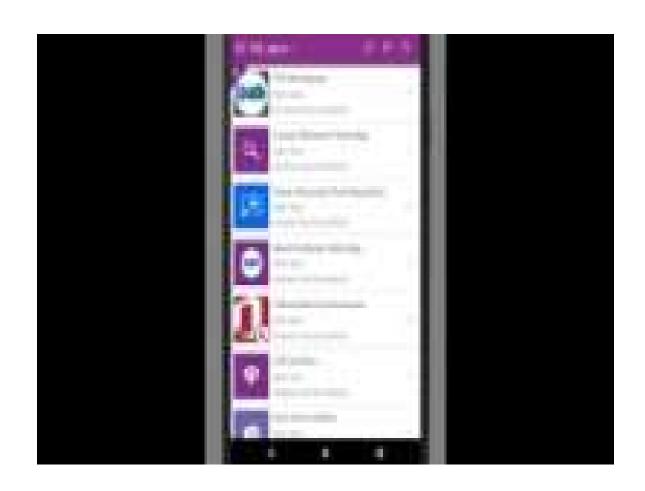
- lets met een barcode scanner dat processen starten: Power Apps Mobile
- lets dat pagina's kan scrapen:
   Azure Functions (in JavaScript,
   Python, C#, PowerShell etc.)
- Een koppeling tussen Azure
   Functions en Power Platform:
   Custom Connectors
- Lijm tussen custom connector en Power Apps: Power Automate

### Hoe doe je dat en wat heb je nodig? Let me google that for you!

- Kosten: voor mijn type tenant en Azure abonnement ben je samen rond de EUR20/m kwijt, je kunt een gratis trial nemen.
- De Azure kant bestaat uit een resource groep, een azure function en een storage account. Zie daarvoor <u>Azure naamgevingsconventies</u>.
- Een nieuwe Azure Function App werkt al. Extra zijn packages om web pagina's in te lezen en te parsen: axios en cheerio voor <u>JavaScript</u> (requests en BeautifulSoup voor Python). Python is gaaf, maar lastiger AAD te beveiligen.
- Web scrapen is legaal, maar houd rekening met het copyright op de informatie.
- Het maken van een AAD protected custom connector is stap voor stap beschreven in dit artikel.
  - Tip 1: daarmee kun je een premium licentie (voor de REST connector) uitstellen of zelfs overbodig maken als je het alleen voor specifieke gevallen nodig hebt.
    Tip 2: als een Power Apps Portal aanmaakt, dan krijg je een echte Dataverse cadeau. Geen idee of dat zo blijft, zo niet, dan werkt het natuurlijk ook met Lists.
- Power Apps werkt niet lekker met het ontvangen van data objecten, of eigenlijk alleen met strings. Met een flow kun je die logica buiten je App houden.
- Screen recording in Android is geblokkeerd, vandaar een <u>emulator</u> filmpje. De barcode is een foto om de camera te simuleren.

# **DEMO**

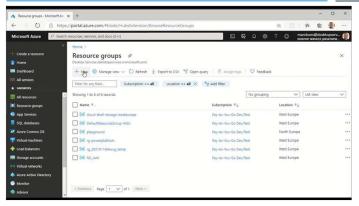
30 seconden demo van het eindresultaat



# **FUNCTION APP**

### Vijf minuten:

- Azure Portal
  - Resource group
  - Function App
- VS Code
  - Function
  - Dependencies
- Validatie



https://youtu.be/lpkoPy0EyIA

WHY: Create resource group

WHERE: WHERE: VS Code

https://portal.azure.com/#blade/HubsExtension/BrowseResourceGrou WHAT: Copy / paste RAW code from presentation to index.js

ns

WHAT: rg\_202102116diwug WHY: Insert dependencies

WHERE: VS Code

WHY: Check

WHERE: Function App

&barcode=080432402825&max=1

WHY: Insert Scraping code

WHAT: Deploy to function app > af-20210216diwug

WHAT: func-20210216diwug-temp > Copy function url > browse to url

WHY: Create Function App WHAT: npm install –save axios cheerio

WHERE: https://portal.azure.com/#create/hub

WHAT: af-20210216diwug > rg\_202102116diwug > Javascript > LTS14 WHY: Deploy > West Europe > stprowerplatform > Review and create WHERE: VS Code

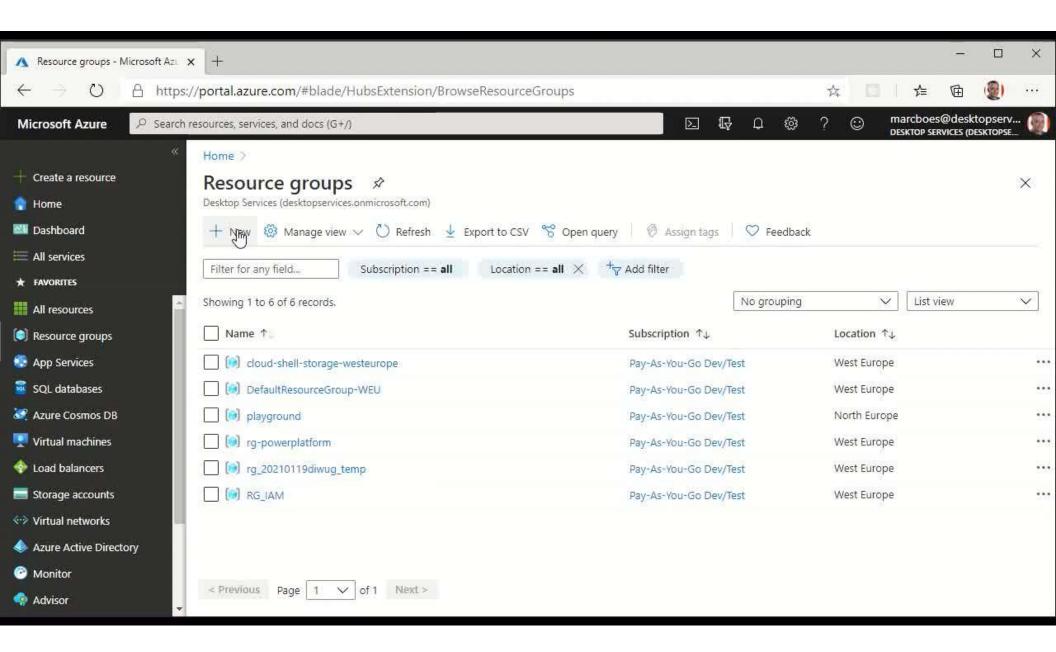
WHY: Create Folder WHERE: D:\Data\2021

WHAT: 20210216DIWUG

WHY: Create Function WHERE: VS Code

WHAT: Console > MKDIR D:\Data\2021\20210216DIWUG

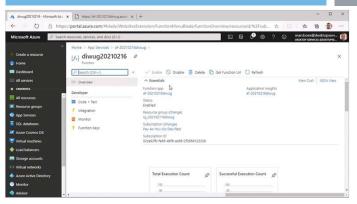
WHAT: Azure > Create new Project > D:\Data\2021\20216DIWUG > Javascript > LTS > HTTP Trigger > diwug20210216 > Function



# **AAD PROTECT APP**

### Twee minuten:

- Azure Portal
  - Protect calls to Azure Functions agains anonymous access
  - Configure AAD authentication provider
- Validatie



https://youtu.be/lpkoPy0EyIA

WHY: Protect calls to Azure Functions against anonymous access

WHERE: Function in Azure Portal

WHAT: diwug20210216 > Authentication / Authorization > Turn on App Service Authentication > Login with AAD

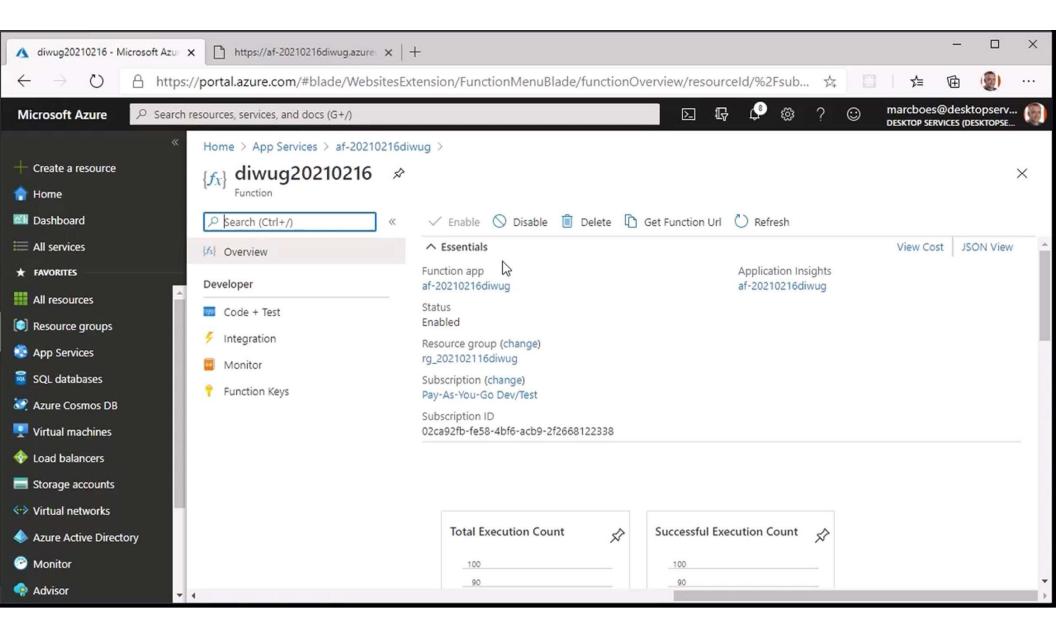
WHY: Configure AAD authentication provider

WHERE: Function in Azure Portal, Authentication / Authorization

WHAT: Azure Active Directory > Express > OK > Save < refresh browser and see 'Express: Existing App'>

WHY: Checking the configuration WHERE: anonymous browser session

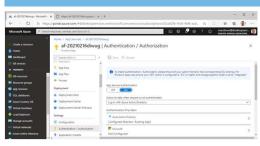
WHAT: browse to url &barcode=080432402825&max=1



# **CUSTOM CONNECTOR**

### Zeven minuten:

- **Azure Portal** 
  - Create app registration for your **Custom Connector in AAD**
  - Get app registration secret for your **Custom Connector in AAD**
- Power Apps
  - **Custom Connectors**
- Validate



https://youtu.be/hKkOKI3Ab34

WHY: Create app registration for your Custom Connector in AAD

https://portal.azure.com/#blade/Microsoft AAD RegisteredApps/Appli cationsListBlade

WHAT: New Registration > af-20210216diwug-conn > Register > API permissions > Add APIs my organization uses > af-20210216diwug > Add user impersonation

WHY: Get app registration secret for your Custom Connector in AAD WHERE:

https://portal.azure.com/#blade/Microsoft\_AAD\_RegisteredApps/Appli **Test** cationsListBlade

WHAT: Certificates & secrets > New client secret > make note of value and client ID in overview.

Note: just to be sure, grant admin consent under API permissions

In Power App Studio, Data, Custom Connectors, create new General

name: af-20210216diwug

logo: D:\Data\Desktop Services\Knowledge Base -

Documents\Resources\Logo-Misc

description: DIWUG Demo

host: af-20210216diwug.azurewebsites.net

OAuth2.0 > Azure Active Directory > Client ID > Client Secret > https://af-20210216diwug.azurewebsites.net

Copy redirect url to connection app registration https://global.consent.azure-apim.net/redirect

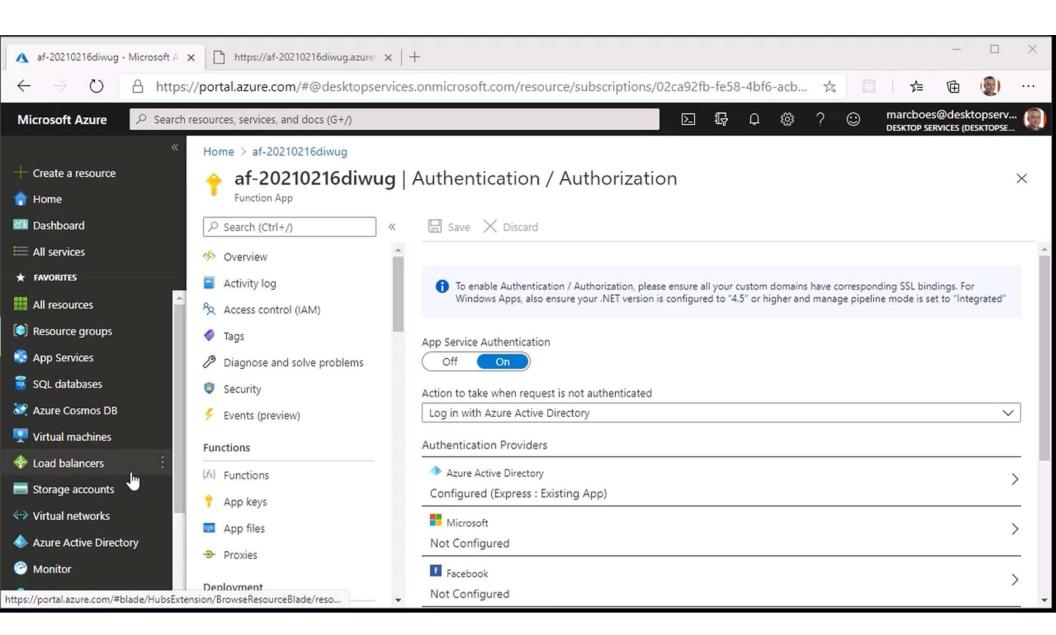
### Definition

- > New Action > DIWUG Demo > DIWUG learn more > DIWUG20210216
- > Request > Import from https://af-

20210119diwug.azurewebsites.net/api/diwug20210119?code=...&ba rcode=080432402825&max=1

- > Request Query: modify the three parameters (default value code. barcode type and required, max required)
- => update before test

WHY: Check that the connector works

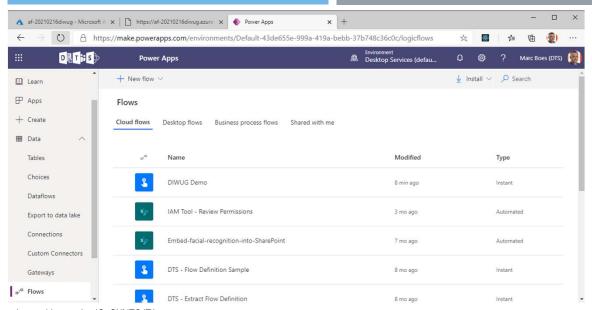


# **POWER PLATFORM**

### Twee minuten:

- Power Automate
- Github
  - Find this presentation and the VS code here:

MJBoes/DIWUG20210216:
Presentation Materials
(github.com)

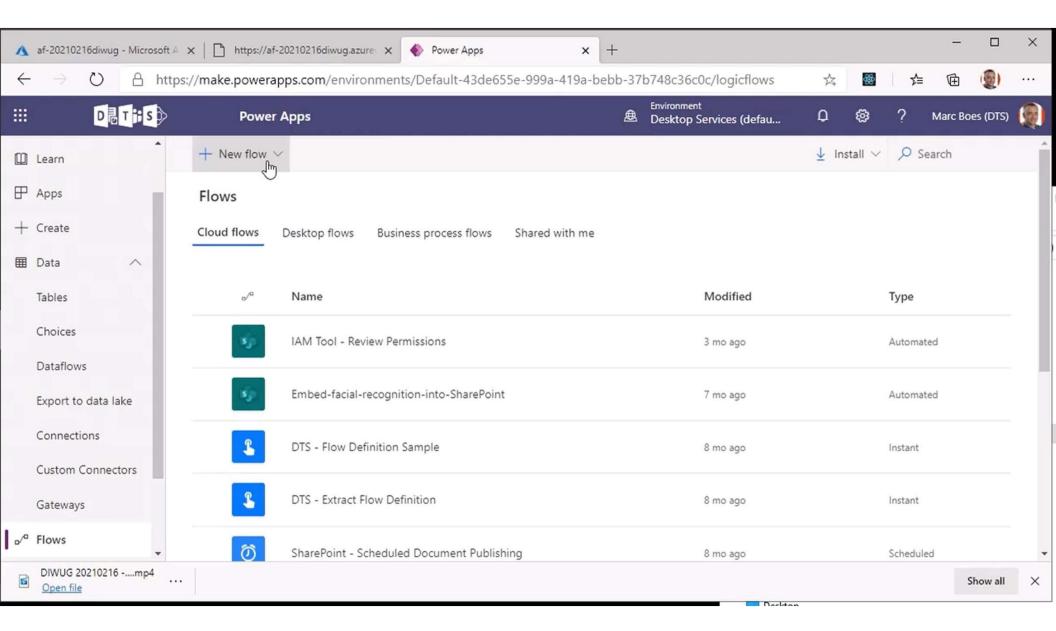


https://youtu.be/Gs2XNTQJTJs

### **Power Automate**

WHY: simple barcode > details validation WHERE: https://make.powerapps.com/

WHAT: new manual flow



# **DANK VOOR DE AANDACHT** EN ALS ER VRAGEN ZIJN & TIJD OVER, DAN KAN DAT NU

# JAVASCRIPT - INDEX.JS

```
const axios = require("axios");
const cheerio = require("cheerio");
                                                                                                           const responseMessage = JSON.stringify(lines);
                                                                                                           context.res = {
    // status: 200, /* Defaults to 200 */
module.exports = async function (context, req) {
    context.log('JavaScript HTTP trigger function processed a request.');
   if(!req.query.barcode||!req.query.max){
                                                                                                               body: responseMessage
        context.res = { status:400,body:"Please pass a barcode and max returned"}
    }else{
       icount=1;
        context.log('https://www.whiskybase.com/search?q='+req.query.barcode);
        const searchpage=await axios.get('https://www.whiskybase.com/search?q='+req.query.barcode
).then(result=>cheerio.load(result.data));
        while(icount<=Math.min(req.query.max,searchpage('.clickable').length)){</pre>
           line={url:searchpage('.clickable')[icount-1].attribs['href']};
           detailspage=await axios.get(line.url).then(result=>cheerio.load(result.data));
           line['name']=detailspage('header h1').text().toString().replace(/\t/g, '').replace(/\
n/g, ' ').trim();
            detailspage('.block-desc dl').each((i,element)=>{
                dd='';dt='
               detailspage(element.childNodes).each((i2,elem)=>{
                    if(elem.name=='dt'){dt=detailspage(elem).text()}
                    if(elem.name=='dd'){
                        dd=detailspage(elem).text()
                        line[dt]=dd;
            icount+=1;
            lines.push(line);
```

# JAVASCRIPT - INDEX.JS (RAW COPY / PASTE VERSION)

```
const axios = require("axios");
                                                                                                                                 const responseMessage = JSON.stringify(lines);
const cheerio = require("cheerio");
                                                                                                                                   // status: 200, /* Defaults to 200 */
module.exports = async function (context, req) {
 context.log('JavaScript HTTP trigger function processed a request.');
                                                                                                                                   body: responseMessage
  if(!req.query.barcode||!req.query.max){
    context.res = { status:400,body:"Please pass a barcode and max returned"}
  }else{
    icount=1;
    lines=[];
    context.log('https://www.whiskybase.com/search?q='+req.query.barcode);
axios.get('https://www.whiskybase.com/search?q='+req.query.barcode).then(result=>cheerio.load(result.data));
    while(icount<=Math.min(req.query.max,searchpage('.clickable').length)){
      line={url:searchpage('.clickable')[icount-1].attribs['href']};
      detailspage=await axios.get(line.url).then(result=>cheerio.load(result.data));
      line['name']=detailspage('header h1').text().toString().replace(/\t/g, ").replace(/\n/g, ' ').trim();
      detailspage('.block-desc dl').each((i,element)=>{
         detailspage(element.childNodes).each((i2,elem)=>{
           if(elem.name=='dt'){dt=detailspage(elem).text()}
           if(elem.name=='dd'){
             dd=detailspage(elem).text()
             line[dt]=dd;
      icount+=1;
      lines.push(line);
```

# PYTHON - \_\_INIT\_\_\_.PY

```
import logging
                                                                                                                   # Build the return object
                                                                                                                   json_record={'Link':ItemURL['href'],'Name':wbname}
import requests
from bs4 import BeautifulSoup
                                                                                                                   i=0
                                                                                                                   while i < len(keys):
import azure.functions as func
                                                                                                                       json_record[keys[i].text]=values[i].text
                                                                                                                   return func.HttpResponse(str(json_record))
def main(req: func.HttpRequest) -> func.HttpResponse:
   logging.info('Python HTTP trigger function processed a request.')
                                                                                                                   return func.HttpResponse(
                                                                                                                         "This HTTP triggered function executed successfully. Pass a parameter in the query s
                                                                                                           tring or in the request body.",
   barcode = req.params.get('barcode')
   if not barcode:
                                                                                                                         status_code=200
            req_body = req.get_json()
        except ValueError:
            barcode=req_body.get('barcode')
        # Scrape the seach result page for the details page url.
        wb_list_url=f"https://www.whiskybase.com/search?q={barcode}"
        wb_list = requests.get(wb_list_url, headers={'User-Agent': 'Mozilla/5.0'}).content
        ItemURL=BeautifulSoup(wb_list, 'html.parser').find_all('a',class_='clickable')[0]
        page = requests.get(ItemURL['href'], headers={'User-Agent': 'Mozilla/5.0'})
        itemPage=BeautifulSoup(page.content, 'html.parser')
       wbname=' '.join(itemPage.find('h1').text.split())
keys=itemPage.find('div', class_='block-desc').find_all('dt')
values=itemPage.find('div', class_='block-desc').find_all('dd')
```

# PYTHON - \_\_INIT\_\_.PY (RAW COPY / PASTE VERSION)

```
import logging
                                                                                                              # Build the return object
import requests
                                                                                                              json_record={'Link':ItemURL['href'],'Name':wbname}
from bs4 import BeautifulSoup
                                                                                                              i=0
                                                                                                              while i < len(keys):
import azure.functions as func
                                                                                                                 json_record[keys[i].text]=values[i].text
                                                                                                             return func.HttpResponse(str(json_record))
def main(req: func.HttpRequest) -> func.HttpResponse:
                                                                                                         else:
   logging.info('Python HTTP trigger function processed a request.')
                                                                                                              return func.HttpResponse(
                                                                                                                   "This HTTP triggered function executed successfully. Pass a parameter in the query
                                                                                                     string or in the request body.",
   barcode = req.params.get('barcode')
   if not barcode:
                                                                                                                   status_code=200
            req_body = req.get_json()
        except ValueError:
           pass
        else:
           barcode=req_body.get('barcode')
        # Scrape the seach result page for the details page url.
        wb_list_url=f"https://www.whiskybase.com/search?q={barcode}"
        wb_list = requests.get(wb_list_url, headers={'User-Agent': 'Mozilla/5.0'}).content
        ItemURL=BeautifulSoup(wb_list, 'html.parser').find_all('a',class_='clickable')[0]
        # Scrape the details page
       page = requests.get(ItemURL['href'], headers={'User-Agent': 'Mozilla/5.0'})
itemPage=BeautifulSoup(page.content, 'html.parser')
        wbname=' '.join(itemPage.find('h1').text.split())
        keys=itemPage.find('div', class_='block-desc').find_all('dt')
        values=itemPage.find('div', class_='block-desc').find_all('dd')
```